

SkyPredict

Uçuş Gecikmesi Erken Uyarı ve Finansal Etki Analizi

Yönetici Özeti Raporu

3.313.919

Analiz Edilen Uçuş

AUC 0.75

Model Doğruluğu

\$1.81M

Net Tasarruf Potansiyeli

Ders: YBS 4 — Python ile Veri Bilimi

Tema: Tema 1: Yapılandırılmış + Yapılandırılmamış Veri ile Tahmin

Veri Kaynağı: 2015 Flight Delays (US DOT) + Historical Weather Data (NOAA)

Yöntem: Data Fusion + Random Forest + Maliyet Odaklı Eşik Optimizasyonu

GitHub: github.com/EmreYsn/SkyPredict

1. Giriş

Uçuş gecikmeleri, havayolu sektöründe yıllık milyarlarca dolarlık kayba neden olan yapısal bir problemdir. Reaktif yaklaşımlar (gecikme olduktan sonra müdahale) yüksek maliyetler doğururken, prediktif modeller sayesinde gecikmeler önceden tespit edilerek proaktif müdahale imkanı oluşturulabilir. Bu proje, ABD'deki 3.3 milyon uçuş kaydını saatlik hava durumu verileriyle birleştirerek gecikme tahmin modeli kurmakta ve modelin havayoluna sağlayacağı somut finansal değeri maliyet/fayda simülasyonu ile ortaya koymaktadır.

2. Veri Harmanlama (Data Fusion)

Projede üç farklı veri kaynağı, havaalanı IATA kodu ve tarih-saat boyutları üzerinden birleştirilmiştir. Uçuş verisindeki havaalanı kodları (LAX, ORD, JFK vb.) önce şehir isimlerine eşlenmiş (32 havaalanı → 27 şehir), ardından her uçuşun kalkış şehri, tarihi ve saatine karşılık gelen hava durumu gözlemleriyle merge edilmiştir.

Veri Kaynağı	Boyut	İçerik
Uçuş Verileri (US DOT, 2015)	5.8M → 3.3M kayıt	Gecikme, rota, havayolu, mesafe, zaman bilgileri
Hava Durumu (NOAA, 2015)	236.000 saatlik kayıt	Sıcaklık, nem, rüzgar hızı, basınç, hava açıklaması
Havaalanı Bilgileri	322 havaalanı	IATA kodu, şehir, eyalet, coğrafi koordinat

Hedef değişken olarak FAA (Federal Havacılık İdaresi) standardına uygun şekilde 15 dakikayı aşan kalkış gecikmeleri ikili sınıflandırma problemi olarak tanımlanmıştır. Veri setinde uçuşların %80.5'i zamanında, %19.5'i gecikmeli olarak sınıflandırılmıştır.

3. Özellik Mühendisliği (Feature Engineering)

Ham değişkenlerin ötesinde, alan bilgisine (domain knowledge) dayalı beş yeni özellik türetilmiştir. Bu özellikler, modelin gecikme nedenlerini kavramasını sağlayan iş mantığı katmanını oluşturmaktadır.

#	Özellik	Hesaplama Formülü	İş Mantığı
1	Hava Durumu Şiddet İndeksi	Rüzgar + nem + kötü hava composite skoru	Kötü hava koşullarının bileşik etkisi
2	Havaalanı Yoğunluk Oranı	Saatlik uçuş / havaalanı ortalaması	Pist kapasitesinin aşılmasıyla artan bekleme
3	Rota Güvenilirlik Skoru	Rota bazlı tarihsel zamanında oranı	Yapısal olarak gecikmeye açık rotalar
4	Kaskad Gecikme Riski	Aynı uçağın önceki bacağındaki gecikme	Gecikmenin sonraki uçuşlara domino etkisi
5	Zaman Bazlı Özellikler	Hafta sonu, yoğun saat, döngüsel ay	Gün içi gecikme birikimi ve mevsimsel etki

4. Keşifçi Veri Analizi (EDA) — Temel Bulgular

Keşifçi veri analizi kapsamında altı farklı görselleştirme ile verinin yapısı incelenmiştir. Tespit edilen temel örüntüler:

- Zaman etkisi:** Gecikme oranı sabah saatlerinde (%12-14) nispeten düşükken, akşam 17:00-21:00 arasında %28-32 seviyelerine yükselmektedir. Bu durum, gün boyunca biriken küçük gecikmelerin akşam uçuşlarına kümülatif olarak yansımalarıyla açıklanmaktadır.
- Hava durumu etkisi:** Kötü hava koşullarında (yağmur, kar, sis, fırtına) gecikme oranı %18'den %22'ye çıkmaktadır.
- Havayolu farklılıkları:** Havayolları arasında gecikme oranlarında %12 ile %26 arasında anlamlı farklılıklar gözlenmiştir.
- Mevsimsel etki:** Yaz ayları (Haziran-Ağustos) ve kış fırtına dönemi (Ocak-Şubat) en yüksek gecikme oranlarını sergilemektedir.

5. Makine Öğrenmesi Modelleme

İki sınıflandırma algoritması karşılaştırılmıştır. Dengesiz sınıf yapısı (%19.5 gecikmeli) nedeniyle her iki modelde de `class_weight='balanced'` parametresi uygulanmıştır. 200.000 örneklemlik stratifiye alt küme üzerinde %80-%20 train-test ayrımı gerçekleştirilmiştir.

Model	AUC-ROC	F1-Score	Precision	Recall
Logistic Regression	0.720	0.434	0.39	0.49
Random Forest	0.747	0.469	0.43	0.52

Random Forest hem AUC hem F1 metriklerinde üstünlük sağlamıştır. Model, gecikmeli uçuşların %52'sini yakalayabilmekte (recall), tahminlerinin %43'ü doğru çıkmaktadır (precision).

6. Açıklanabilir Yapay Zeka (XAI)

Random Forest'ın Gini tabanlı özellik önem sıralaması analiz edilmiştir:

Sıra	Özellik	Önem Skoru	Yorum
1	prev_delay (Kaskad Gecikme)	0.232	En güçlü tahmin edici — domino etkisi
2	hour (Kalkış Saati)	0.149	Akşam uçuşları belirgin şekilde riskli
3	cascade_risk	0.125	Önceki uçuş 15+ dk gecikmişse yüksek risk
4	route_ontime_rate	0.073	Kronik gecikmeli rotalar tespit ediliyor
5	temperature	0.057	Aşırı sıcaklıklar gecikme riskini artırıyor

7. Maliyet/Fayda Simülasyonu ve Optimal Eşik

Bu bölüm, modelin teknik başarısını somut finansal değere dönüştürmektedir. Temel senaryo: gecikme riski yüksek olarak tahmin edilen uçuşlardaki yolcuların proaktif olarak alternatif uçuşlara yönlendirilmesi ile reaktif maliyet kalemlerinin azaltılmasıdır.

Senaryo Parametreleri

Parametre	Değer	Açıklama
Reaktif Maliyet	\$500	Gecikme sonrası: tazminat + otel + yemek + marka değer kaybı
Proaktif Rebooking	\$150	Erken tespit ile yolcu yönlendirme maliyeti
Yanlış Alarm Maliyeti	\$30	Gereksiz bildirim operasyonel maliyeti
Optimal Eşik	0.28	Net tasarrufu maksimize eden karar eşiği

Eşik Optimizasyonu

Standart sınıflandırma eşiği 0.50 yerine maliyet odaklı optimizasyon yapılmıştır. Bir gecikmeyi kaçırmanın maliyeti (\$500) yanlış alarmdan (\$30) yaklaşık 17 kat fazladır. Bu asimetri nedeniyle, daha düşük eşik ile daha fazla potansiyel gecikme yakalanması toplam maliyeti düşürmektedir. Net tasarruf fonksiyonu: $(TP \times \$350) - (FP \times \$30)$ formülünün 0.05-0.95 eşik aralığında maksimize edilmesiyle optimal eşik 0.28 olarak belirlenmiştir.

Senaryo Karşılaştırması

Senaryo	Doğru Tespit (TP)	Yanlış Alarm (FP)	Net Tasarruf
Model Yok (tüm gecikmeler reaktif)	—	—	\$0
Standart Eşik (0.50)	3.603	4.723	~\$1.25M
Optimal Eşik (0.28)	5.816	10.878	~\$1.81M

Optimal eşik uygulaması ile standart yaklaşıma göre %45 daha fazla tasarruf sağlanmaktadır. Yanlış alarm sayısı artmakla birlikte, her bir yanlış alarmın düşük maliyeti (\$30) bu artışı kolaylıkla telafi etmektedir.

8. Sonular ve İř Önerileri

Bu projede, 3.3 milyon uuř kaydı ile 236.000 saatlik hava durumu gözlemi birleřtirilerek uuř gecikmesi tahmin modeli geliřtirilmiřtir. Ü farklı veri kaynağının data fusion ile birleřtirilmesi, beř iř mantığı tabanlı yeni deėiřkenin türetilmesi ve maliyet odaklı eřik optimizasyonu ile model salt teknik bir araçtan iř deėeri üreten bir karar destek sistemine dönüřtürölmüřtür.

Temel Bulgular

- Kaskad gecikme en güçlü tahmin edicidir (importance: 0.23). Havacılıkta bilinen domino etkisi, model tarafından en yüksek önem skoru ile doğrulanmıřtır.
- Zamansal birikim gecikmelerin temel dinamiğidir. Akřam saatlerinde gecikme oranı sabaha göre 2-3 kat artmaktadır.
- Hava durumu gecikme oranını %18'den %22'ye çıkarmaktadır. Hava durumu řiddet indeksi bu etkiyi başarıyla yakalamaktadır.
- Optimal eřik uygulaması ile standart yaklařıma göre %45 daha fazla tasarruf saėlanmaktadır (\$1.25M → \$1.81M).

İř Önerileri

- Erken Uyarı Sistemi: Model, kalkıřtan 2-3 saat önce gecikme olasılığı üretebilir. Eřiėi ařan uuřlar için operasyon merkezine otomatik uyarı gönderilmelidir.
- Kaskad Yönetimi: Geciken bir uağın sonraki tüm bacakları otomatik izlemeye alınmalı, yolcular proaktif olarak bilgilendirilmelidir.
- Kapasite Planlaması: Yoğun saat ve kötü hava durumu kombinasyonlarında ekstra pist slotu ve yedek uak kapasitesi planlanmalıdır.
- Rota Optimizasyonu: Kronik gecikmeli rotaların lojistik altyapısı gözden geirilmeli, gerekirse sefer planı revize edilmelidir.

Sonu: Bu proje, yapılandırılmıř uuř verileri ile yapılandırılmamıř hava durumu gözlemlerini birleřtirerek uuř gecikmelerini %75 doğrulukla (AUC) tahmin eden bir Random Forest modeli geliřtirmiřtir. Maliyet/fayda simölasyonu ile havayoluna yıllık ~\$1.81M net tasarruf saėlama potansiyeli gösterilmiř, modelin stratejik bir karar destek sistemi olarak konumlandırılabilieceėi ortaya konmuřtur.